Вычислительные эксперименты

Постановка

Модель: Qwen 3.6 27B.
Сервер: 2Тб ОЗУ, 164Гб видеопамяти (2 видеокарты A100 на 82Гб), 128 ядер процессора.
Развёртка: vLLM, tensor-parallel-size=2, gpu-utility=0.92.
Датасет: Spider 2.0-lite без BigQuery примеров (всего 342 примера).

Оценка

Крайние случаи

Алгоритм	EX, истинный, %	EX, среди исполнимых запросов, %	Всего верных запросов	Всего исполнимых запросов
Только генерация	17.25	43.70	59	135
Полный, с агентом связывания схемы, 5 кандидатов	45.32	48.14	155	322

Полный алгоритм: агент связывания схемы, исследовательские запросы, генерация, синтаксическое и семантическое исправление, выбор финального SQL.

Инструменты агента связывания схемы

Набор инструментов агента	EX, истинный, %	ΔEX, %	EX, среди исполнимых запросов, %	Всего верных запросов	Всего исполнимых запросов
Все инструменты	18.13	0.0	44.60	62	139
-schema_exploration	16.96	-1.17	41.43	58	140
-sql_draft	16.96	-1.17	44.62	58	130

Набор инструментов агента	EX, истинный, %	ΔEX, %	EX, среди исполнимых запросов, %	Всего верных запросов	Всего исполнимых запросов
-schema_exploration и -sql_draft	16.96	-1.17	42.65	58	136
Только векторный поиск	16.37	-1.76	41.48	56	135

ΔEX - разница истинного **EX** между алгоритмом с полным набором инструментов агента и текущим.

Полный алгоритм: агент связывания схемы, генерация.

Связывание схемы, основанное на LLM

Алгоритм связывания схемы	EX, истинный, %	ΔEX, %	EX, среди исполнимых запросов, %	Всего верных запросов	Всего исполнимых запросов
Агент	18.13	0.0	44.60	62	139
Только столбцы	15.50	-2.63	37.59	53	141
Только таблицы	15.21	-2.92	37.68	52	138
От столбцов к таблицам	15.21	-2.92	38.24	52	136
От таблиц к столбцам	16.96	-1.17	41.43	58	140
Двунаправленный	15.79	-2.34	38.30	54	141

ΔEX - разница истинного **EX** между агентной реализацией связывания схемы текущей.

Полный алгоритм: связывание схемы, генерация.

Исследовательские запросы

Алгоритм связывания схемы	EX, истинный, %	ΔEX, %	EX, среди исполнимых запросов, %	Всего верных запросов	Всего исполнимых запросов
Только столбцы	15.21	-0.29	37.41	52	139

Алгоритм связывания схемы	**EX, истинный, %**	$\Delta\mathrm{EX}$, **%**	**EX, среди исполнимых запросов, %**	**Всего верных запросов**	**Всего исполнимых запросов**
От таблиц к столбцам	15.21	-1.75	36.11	52	144
Двунаправленный	15.79	0.0	38.85	54	139
Агент	15.79	-2.34	39.42	54	137

$\Delta\mathrm{EX}$ - разница истинного **EX** до и после применения генерации исследовательских столбцов.

Полный алгоритм: связывание схемы, исследовательские запросы, генерация.